LLM-Integration Architektur

Planung für intelligente Konversationen

Inhaltsverzeichnis

Übersicht

Die LLM-Integration erweitert den Voice Assistant von einem einfachen Befehlsausführungs-System zu einem intelligenten Konversations-Partner. Statt nur

vordefinierte Befehle auszuführen, kann der Assistant komplexe Fragen beantworten, Recherchen durchführen und kontextbasierte Gespräche führen.

Aktueller Zustand (v3.0)

Der Voice Assistant funktioniert derzeit nach einem einfachen Pattern-Matching-Prinzip:

```
User: "Computer, öffne YouTube"
  → Pattern erkannt: "youtube" in command_lower
  → Aktion: webbrowser.open("https://www.youtube.com")
  → Response: "Öffne YouTube"
```

Limitierungen:

- Nur vordefinierte Befehle funktionieren
- Keine Fragen beantwortbar (“Wie wird das Wetter?”)
- Keine Konversation möglich
- Keine Kontextspeicherung

Ziel-Zustand (v4.0 mit LLM)

Mit LLM-Integration wird der Assistant intelligent:

```
User: "Computer, wie wird das Wetter morgen in Berlin?"
  → Klassifizierung: FRAGE (kein Befehl)
  → LLM-Aufruf: Perplexity API
  → Response: "Morgen wird es in Berlin sonnig mit 18 Grad..."

User: "Computer, schreibe eine E-Mail an Max über das Meeting"
  → Klassifizierung: KOMPLEXE AUFGABE
  → LLM-Aufruf: ChatGPT API
  → Response: "Ich habe einen E-Mail-Entwurf erstellt: ..."
```

Warum LLM-Integration?

Vorteile

Natürliche Konversation: Nutzer können in natürlicher Sprache sprechen, ohne sich an spezifische Befehlsformate erinnern zu müssen. Statt "öffne YouTube" kann man fragen "Kannst du mir YouTube öffnen?" oder "Ich möchte Videos schauen".

Intelligente Antworten: Der Assistant kann komplexe Fragen beantworten, die nicht vorprogrammiert sind. Wetter-Abfragen, Fakten-Recherche, Berechnungen, Übersetzungen und vieles mehr werden möglich.

Kontext-Verständnis: LLMs können den Kontext eines Gesprächs verstehen und darauf aufbauen. Folgefragen wie "Und übermorgen?" werden korrekt interpretiert.

Erweiterbarkeit: Neue Funktionen können durch Prompt-Engineering hinzugefügt werden, ohne Code zu ändern. Der Assistant lernt durch bessere Prompts.

Personalisierung: LLMs können sich an Nutzerpräferenzen anpassen und personalisierte Antworten geben.

Herausforderungen

Latenz: API-Aufrufe zu externen LLMs dauern 1-5 Sekunden, was die Reaktionszeit erhöht.

Kosten: ChatGPT und andere APIs sind kostenpflichtig (ca. $0.001-0.01 pro Anfrage).

Internetabhängigkeit: Ohne Internet funktionieren Cloud-LLMs nicht.

Datenschutz: Audio/Text wird an externe Server gesendet (OpenAI, Perplexity, etc.).

Zuverlässigkeit: API-Ausfälle oder Rate-Limits können die Funktionalität beeinträchtigen.

Architektur-Design

High-Level Architektur

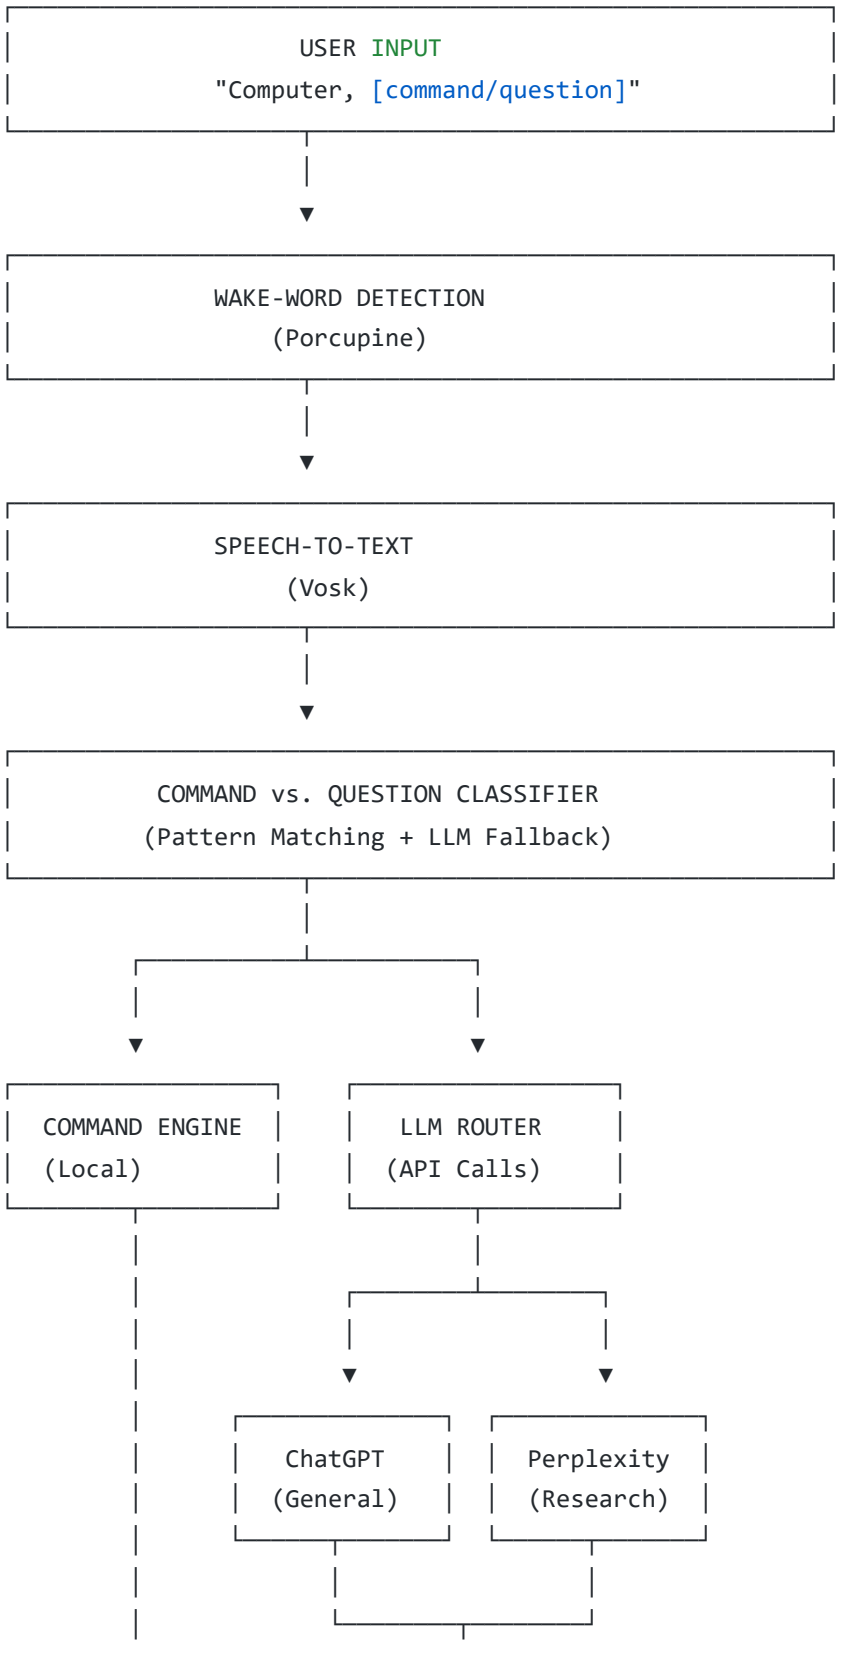

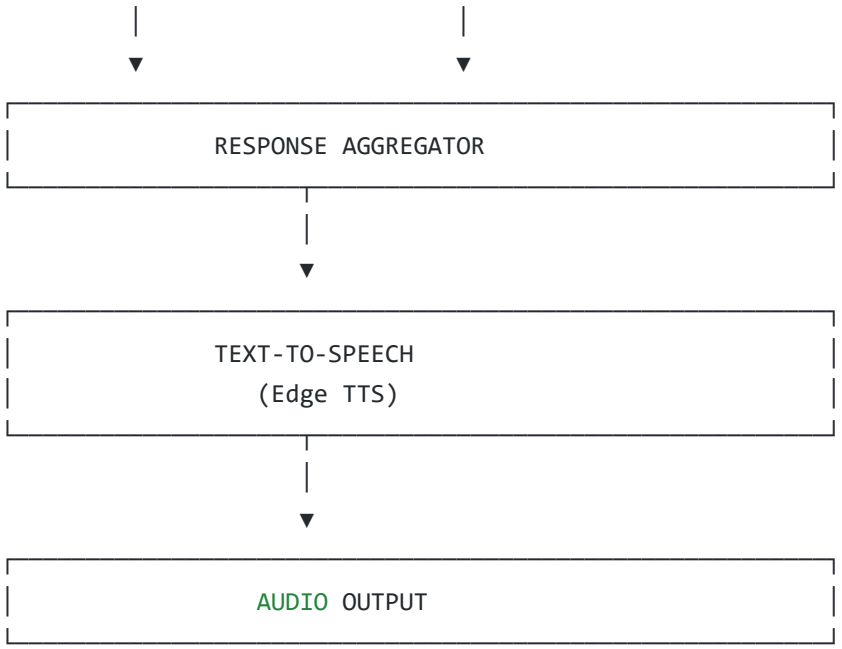

Komponenten-Beschreibung

Wake-Word Detection: Aktiviert den Assistant (bereits implementiert mit Porcupine).

Speech-to-Text: Konvertiert Sprache zu Text (bereits implementiert mit Vosk).

Classifier: Entscheidet, ob Input ein Befehl oder eine Frage ist. Dies ist die zentrale neue Komponente.

Command Engine: Führt lokale Befehle aus (bereits implementiert).

LLM Router: Wählt das passende LLM basierend auf Anfrage-Typ.

LLM APIs: ChatGPT für allgemeine Fragen, Perplexity für Recherche, etc.

Response Aggregator: Kombiniert Antworten und formatiert sie für TTS.

Text-to-Speech: Spricht die Antwort (bereits implementiert mit Edge TTS).

LLM-Auswahl

ChatGPT (OpenAI)

Anwendungsfall: Allgemeine Konversation, Kreativität, Textgenerierung

Stärken:

- Sehr gute natürliche Sprache
- Kontextverständnis
- Kreative Antworten
- Multimodal (Text, Code, Reasoning)

Schwächen:

- Wissen nur bis Trainings-Cutoff (2023)
- Keine Echtzeit-Informationen
- Kann "halluzinieren" (falsche Fakten)

Kosten:

- GPT-4o: $0.005/1K input tokens$,0.015/1K output tokens
- GPT-4o-mini: $0.00015/1K input tokens$,0.0006/1K output tokens

API-Beispiel:

```
from openai import OpenAI
client = OpenAI(api_key="sk-...")

response = client.chat.completions.create(
    model="gpt-4o-mini",
    messages=[
        {"role": "system", "content": "Du bist ein hilfreicher Voice Assistant."},
        {"role": "user", "content": "Wie wird das Wetter morgen?"}
    ]
)
answer = response.choices[0].message.content
```

Empfehlung: Nutze für allgemeine Fragen, Kreativität, E-Mail-Entwürfe, Zusammenfassungen.

Perplexity

Anwendungsfall: Recherche, aktuelle Informationen, Fakten-Check

Stärken:

- Echtzeit-Websuche
- Zitiert Quellen
- Aktuelle Informationen (Wetter, News, etc.)
- Fakten-basiert (weniger Halluzinationen)

Schwächen:

- Weniger kreativ als ChatGPT
- Fokus auf Fakten, nicht Konversation
- Teurer als ChatGPT

Kosten:

- Sonar (Standard): $0.005/1K tokens
- Sonar Pro: $0.01/1K tokens

API-Beispiel:

```
import requests

url = "https://api.perplexity.ai/chat/completions"
headers = {
    "Authorization": "Bearer pplx-...",
    "Content-Type": "application/json"
}
data = {
    "model": "sonar",
    "messages": [
        {"role": "user", "content": "Wie wird das Wetter morgen in Berlin?"}
    ]
}

response = requests.post(url, headers=headers, json=data)
answer = response.json()["choices"][0]["message"]["content"]
```

Empfehlung: Nutze für Wetter, News, Fakten-Recherche, aktuelle Events.

Manus

Anwendungsfall: Komplexe Aufgaben, Multi-Step-Reasoning, Tool-Use

Stärken:

- Kann Tools nutzen (Browser, Code, etc.)
- Multi-Step-Reasoning
- Komplexe Aufgaben automatisieren
- Sehr gutes Verständnis

Schwächen:

- Langsamer (mehrere Sekunden)
- Komplexere Integration
- Nicht für einfache Fragen geeignet

Kosten: Abhängig von Manus-Subscription

Empfehlung: Nutze für komplexe Aufgaben wie "Erstelle eine Präsentation über KI" oder "Recherchiere und fasse zusammen".

Lokale LLMs (Optional)

Anwendungsfall: Offline-Nutzung, Datenschutz

Optionen:

- Ollama (Llama 3, Mistral, etc.)
- LM Studio
- GPT4All

Stärken:

- Vollständig offline
- Keine API-Kosten
- Datenschutz (nichts verlässt PC)

Schwächen:

- Benötigt leistungsstarke GPU (8GB+ VRAM)
- Langsamer als Cloud-LLMs
- Weniger intelligent als GPT-4

Empfehlung: Für zukünftige Version als Fallback implementieren.

Command vs. Question Classification

Klassifizierungs-Strategie

Die Klassifizierung entscheidet, ob ein Input ein **Befehl** (lokal ausführbar) oder eine **Frage** (LLM-Anfrage) ist.

Methode 1: Pattern-Based (Schnell, Offline)

Befehl-Patterns:

```
COMMAND_KEYWORDS = [
    "öffne", "starte", "schließe", "zeige", "spiele",
    "öffnen", "starten", "schließen", "zeigen", "spielen",
    "mach", "mache", "erstelle", "lösche"
]

def is_command(text):
    text_lower = text.lower()
    for keyword in COMMAND_KEYWORDS:
        if keyword in text_lower:
            return True
    return False
```

Frage-Patterns:

```
QUESTION_KEYWORDS = [
    "wie", "was", "wer", "wann", "wo", "warum", "welche",
    "erkläre", "sage mir", "erzähle", "beschreibe"
]

def is_question(text):
    text_lower = text.lower()
    for keyword in QUESTION_KEYWORDS:
        if text_lower.startswith(keyword):
            return True
    if "?" in text:
        return True
    return False
```

Vorteile: Schnell, offline, keine API-Kosten **Nachteile:** Ungenau, viele Edge-Cases

---

Methode 2: LLM-Based Classification (Genau, Online)

Nutze ein kleines, schnelles LLM (GPT-4o-mini) zur Klassifizierung:

```
def classify_intent(text):
    """Klassifiziert Input als COMMAND, QUESTION oder CONVERSATION."""

    prompt = f"""Klassifiziere folgende Nutzer-Eingabe:

Input: "{text}"

Kategorien:
- COMMAND: Befehl zum Ausführen einer Aktion (öffne, starte, etc.)
- QUESTION: Frage, die eine Antwort benötigt (wie, was, wann, etc.)
- CONVERSATION: Smalltalk oder Höflichkeit (hallo, danke, etc.)

Antworte nur mit: COMMAND, QUESTION oder CONVERSATION"""

    response = client.chat.completions.create(
        model="gpt-4o-mini",
        messages=[{"role": "user", "content": prompt}],
        max_tokens=10,
        temperature=0
    )

    classification = response.choices[0].message.content.strip()
    return classification
```

Vorteile: Sehr genau, versteht Kontext **Nachteile:** Latenz (+500ms), API-Kosten

---

Methode 3: Hybrid (Empfohlen)

Kombiniere beide Methoden:

```python
def classify_input(text):
    """Hybrid-Klassifizierung: Pattern-based first, LLM fallback."""

    # 1. Schnelle Pattern-Checks
    if is_command(text):
        return "COMMAND"

    if is_question(text):
        return "QUESTION"

    # 2. Spezielle Fälle
    if any(word in text.lower() for word in ["danke", "hallo", "tschüss"]):
        return "CONVERSATION"

    # 3. LLM-Fallback für unklare Fälle
    return classify_intent(text)  # LLM-Aufruf
```

Vorteile: Schnell für klare Fälle, genau für unklare Fälle **Nachteile:** Etwas komplexer

---

API-Integration

ChatGPT API Integration

```
from openai import OpenAI
import os
from dotenv import load_dotenv

load_dotenv()

class ChatGPTAssistant:
    def __init__(self):
        self.client = OpenAI(api_key=os.getenv('OPENAI_API_KEY'))
        self.conversation_history = []

    def query(self, user_input):
        """Sendet Anfrage an ChatGPT und gibt Antwort zurück."""

        # Füge Nutzer-Input zu History hinzu
        self.conversation_history.append({
            "role": "user",
            "content": user_input
        })

        # System-Prompt
        messages = [
            {
                "role": "system",
                "content": "Du bist ein hilfreicher deutscher Voice Assistant
namens Computer. "
                           "Antworte kurz und prägnant (max 2-3 Sätze). "
                           "Nutze natürliche, gesprochene Sprache."
            }
        ] + self.conversation_history

        # API-Aufruf
        try:
            response = self.client.chat.completions.create(
                model="gpt-4o-mini",
                messages=messages,
                max_tokens=150,  # Kurze Antworten für Voice
                temperature=0.7
            )
```

```
            answer = response.choices[0].message.content

            # Füge Antwort zu History hinzu
            self.conversation_history.append({
                "role": "assistant",
                "content": answer
            })

            # Limitiere History-Länge (letzte 10 Nachrichten)
            if len(self.conversation_history) > 10:
                self.conversation_history = self.conversation_history[-10:]

            return answer

        except Exception as e:
            print(f"ChatGPT API Error: {e}")
            return "Entschuldigung, ich konnte keine Verbindung herstellen."
```

Perplexity API Integration

```python
import requests
import os

class PerplexityAssistant:
    def __init__(self):
        self.api_key = os.getenv('PERPLEXITY_API_KEY')
        self.url = "https://api.perplexity.ai/chat/completions"

    def query(self, user_input):
        """Sendet Recherche-Anfrage an Perplexity."""

        headers = {
            "Authorization": f"Bearer {self.api_key}",
            "Content-Type": "application/json"
        }

        data = {
            "model": "sonar",
            "messages": [
                {
                    "role": "system",
                    "content": "Du bist ein Recherche-Assistent. "
                               "Gib kurze, faktische Antworten mit Quellen."
                },
                {
                    "role": "user",
                    "content": user_input
                }
            ],
            "max_tokens": 200
        }

        try:
            response = requests.post(self.url, headers=headers, json=data)
            response.raise_for_status()

            answer = response.json()["choices"][0]["message"]["content"]
            return answer

        except Exception as e:
            print(f"Perplexity API Error: {e}")
            return "Entschuldigung, ich konnte keine Informationen finden."
```

Fallback-Strategie

Multi-Tier Fallback

```
class LLMRouter:
    def __init__(self):
        self.chatgpt = ChatGPTAssistant()
        self.perplexity = PerplexityAssistant()

    def route_query(self, text, intent):
        """Routet Anfrage zum passenden LLM mit Fallback."""

        # 1. Bestimme primäres LLM
        if intent == "QUESTION":
            # Recherche-Fragen → Perplexity
            if any(word in text.lower() for word in ["wetter", "news", "aktuell"]):
                primary = self.perplexity
                fallback = self.chatgpt
            else:
                # Allgemeine Fragen → ChatGPT
                primary = self.chatgpt
                fallback = self.perplexity
        else:
            # Konversation → ChatGPT
            primary = self.chatgpt
            fallback = None

        # 2. Versuche primäres LLM
        try:
            answer = primary.query(text)
            if answer and "Entschuldigung" not in answer:
                return answer
        except Exception as e:
            print(f"Primary LLM failed: {e}")

        # 3. Fallback zu sekundärem LLM
        if fallback:
            try:
                answer = fallback.query(text)
                return answer
            except Exception as e:
                print(f"Fallback LLM failed: {e}")

        # 4. Offline-Fallback
```

```
        return "Entschuldigung, ich kann momentan keine Verbindung herstellen.
Versuche es später erneut."
```

Code-Struktur

Integration in Voice Assistant

```python
# In voice_assistant_computer.py

from llm_integration import LLMRouter, classify_input

# Initialisierung
llm_router = LLMRouter()

# In main loop, nach STT:
command = result.get("text", "")

if command:
    print(f"📝 [STT] Erkannt: \"{command}\"")

    # Klassifiziere Input
    intent = classify_input(command)
    print(f"🔍 [CLASSIFIER] Intent: {intent}")

    if intent == "COMMAND":
        # Lokale Befehlsausführung
        execute_command(command)

    elif intent in ["QUESTION", "CONVERSATION"]:
        # LLM-Anfrage
        print("🤖 [LLM] Sende Anfrage...")
        answer = llm_router.route_query(command, intent)
        print(f"💬 [LLM] Antwort: {answer}")
        speak(answer)

    else:
        speak("Befehl nicht verstanden")
```

Implementierungs-Roadmap

Phase 1: Basis-Integration (1-2 Tage)

```
[ ] OpenAI API-Key besorgen
[ ] ChatGPT Integration implementieren
[ ] Einfache Klassifizierung (Pattern-based)
[ ] Testing mit 10 Beispiel-Fragen
[ ] Dokumentation
```

Phase 2: Erweiterte Features (3-5 Tage)

```
[ ] Perplexity API-Key besorgen
[ ] Perplexity Integration implementieren
[ ] LLM-Router mit Fallback
[ ] Konversations-History
[ ] Hybrid-Klassifizierung
```

Phase 3: Optimierung (1 Woche)

```
[ ] Latenz-Optimierung (Streaming)
[ ] Caching für häufige Fragen
[ ] Kosten-Monitoring
[ ] Erweiterte Fehlerbehandlung
[ ] Performance-Tests
```

Phase 4: Erweiterte LLMs (Optional)

```
[ ] Manus Integration
[ ] Lokales LLM (Ollama) als Offline-Fallback
[ ] Multi-Modal (Bilder, Dokumente)
```

Dokumentende